Avaliação Exploratória de um Modelo Compacto de *Tool-Calling* para Interfaces de Comando em Português no Contexto de IoT Apícola

Renato William Rodrigues de Souza, Luiz Henrique de Sousa Vieira
João Isaac Silva Miranda, Lívia Pereira Mota
Valdenio Mendes Mascena

[1] Instituto Federal de Educação, Ciência e Tecnologia do Ceará (IFCE) - Campus Boa Viagem

Resumo. *Este trabalho apresenta uma avaliação exploratória do Needle 2, modelo compacto de tool-calling com aproximadamente 45 milhões de parâmetros, para interpretar comandos em português no contexto de IoT apícola. Foram avaliadas 36 solicitações em um motor de referência executado em host e em um ESP32-S3 N16R8 físico, utilizando o mesmo conjunto de comandos e ferramentas. Segundo o gabarito histórico, com 33 casos avaliáveis, a acurácia exata foi de 39,39% no host e 42,42% no ESP32-S3. As sequências de chamadas coincidiram em 34 das 36 solicitações (94,44%). No microcontrolador, a latência total média foi de 35,85 s e a taxa média de geração foi de 1,378 token/s. A reavaliação retrospectiva revelou dificuldades do modelo em reconhecer situações que exigiam abstenção, especialmente diante de comandos ambíguos ou não contemplados pelas ferramentas disponíveis. Embora todas as 36 solicitações tenham sido processadas no ESP32-S3, a geração de chamadas funcionalmente corretas permaneceu limitada. Ressalta-se que o experimento avaliou exclusivamente a interpretação dos comandos e a geração de chamadas estruturadas, sem executar operações sobre sensores ou atuadores.*

Abstract. *This paper presents an exploratory evaluation of Needle 2, a compact tool-calling model with approximately 45 million parameters, for interpreting Portuguese commands in an apiculture IoT scenario. We evaluated 36 requests using both a host reference engine and a physical ESP32-S3 N16R8, with the same commands and tool definitions. Under the original reference annotations, which contained 33 evaluable cases, exact-match accuracy was 39.39% on the host and 42.42% on the ESP32-S3. The two environments produced identical tool-call sequences for 34 of the 36 requests (94.44%). On the microcontroller, mean end-to-end latency was 35.85 s and mean generation throughput was 1.378 tokens/s. A retrospective reassessment revealed difficulties in abstaining from ambiguous or unsupported requests. Although the ESP32-S3 successfully processed all 36 requests, the functional correctness of the generated tool calls remained limited. The experiment was restricted to generating and evaluating structured tool calls, without executing the tools or activating sensors and actuators.*

1. Introdução

Sistemas baseados em Internet da coisas (IoT) permitem monitorar colmeias e reduzir inspeções manuais frequentes [Henry et al. 2019, Meikle and Holst 2015]. No semiárido,

distâncias entre propriedades e conectividade instável dificultam a supervisão remota. Embora painéis web e comandos seriais permitam consultar dados e configurar dispositivos, sua operação pode exigir conhecimentos técnicos pouco acessíveis a alguns produtores.

Modelos de linguagem podem facilitar essa interação, mas a inferência convencional frequentemente exige recursos incompatíveis com microcontroladores ou serviços em nuvem. Modelos compactos de *tool-calling* oferecem uma alternativa local. O Needle 2, divulgado com aproximadamente 45 milhões de parâmetros, é um exemplo dessa abordagem; seus resultados públicos, porém, não estabelecem seu desempenho em português no domínio apícola [Cactus Compute 2026].

O Needle 2 integra a família de modelos compactos de *tool-calling* disponibilizada pela Cactus Compute. Segundo a documentação do projeto, a versão utilizada emprega quantização CQ2-bit e possui um arquivo de pesos de aproximadamente 14 MB, com estimativa de cerca de 28 MB de memória para uma sessão de inferência [Cactus Compute 2026]. Esses valores correspondem às especificações divulgadas pelos desenvolvedores, não a medições de consumo de memória realizadas neste estudo. A pesquisa sobre *Simple Attention Networks* oferece fundamentação arquitetural relacionada [Ndubuaku et al. 2026], sem que isso implique atribuir ao Needle 2 todos os componentes descritos em outras versões da família.

Outros modelos compactos de *function-calling* incluem FunctionGemma (270M) e LFM2.5 (230M). O TinyAgent investiga a especialização de modelos para essa tarefa por meio de *fine-tuning* [Erdogan et al. 2024]. Esses trabalhos motivam avaliar a geração de chamadas estruturadas por modelos menores em domínios específicos.

A interface avaliada neste trabalho recebe comandos em texto, e não diretamente em áudio. Embora o hardware utilizado disponha de microfone integrado, seu uso não faz parte do escopo desta avaliação e é considerado como possibilidade de trabalho futuro. Soluções como a ESP-SR [Espressif Systems 2026] permitem reconhecimento local de palavras-chave em dispositivos ESP32, mas operam com vocabulários previamente definidos. Neste trabalho, o interesse está na interpretação de diferentes formulações textuais em linguagem natural para sua conversão em chamadas estruturadas de ferramentas.

No contexto da apicultura de precisão, sistemas baseados em sensores permitem acompanhar variáveis como peso, temperatura e umidade das colmeias [Henry et al. 2019, Meikle and Holst 2015, Danieli et al. 2024]. Neste trabalho, o interesse está na camada de interação com esses sistemas, investigando a conversão de comandos em português em chamadas estruturadas de ferramentas, e não no processamento ou na análise dos sinais coletados. Revisões recentes sobre apicultura de precisão destacam que a adoção dessas tecnologias envolve, além do sensoriamento, aspectos relacionados à usabilidade e à interação com o produtor [Danieli et al. 2024]. Nesse contexto, este trabalho investiga de forma exploratória o uso do Needle 2 como interface local de comando em português para um cenário de IoT aplicado à apicultura. O estudo concentra-se em um cenário ainda pouco explorado: a utilização de um modelo compacto de *tool-calling*, executável em microcontrolador, para interpretar comandos em português associados a operações de monitoramento apícola.

As principais contribuições deste trabalho são: (1) a definição de um cenário expe-

rimental de *tool-calling* para IoT apícola, composto por três ferramentas e 36 solicitações em português brasileiro; (2) a avaliação da correção funcional das chamadas geradas pelo Needle 2, incluindo seleção de ferramentas, argumentos e abstenção; (3) a execução sistemática das 36 solicitações em um ESP32-S3 N16R8 físico, com caracterização de latência, taxa de geração e memória; e (4) a comparação das chamadas produzidas no motor host de referência e no microcontrolador, incluindo concordância entre saídas e padrões de erro. A avaliação concentra-se na geração de chamadas estruturadas: não houve execução de ferramentas sobre sensores ou atuadores, nem validação em campo com apicultores. Essas limitações são discutidas na Seção 4.

O restante deste artigo está organizado da seguinte forma: a Seção 2 descreve a proposta, o ambiente experimental, o *schema* de ferramentas, o conjunto de teste e o protocolo de avaliação; a Seção 3 apresenta os resultados quantitativos e qualitativos; a Seção 4 discute as implicações dos resultados e as limitações do trabalho; e a Seção 5 apresenta as conclusões.

2. Metodologia

2.1. Proposta

A proposta consiste em utilizar um modelo compacto de *tool-calling* como camada de interpretação entre comandos em linguagem natural e operações de um sistema de monitoramento apícola. Foram definidas três ferramentas representativas de consultas e ações nesse domínio, mantendo o *schema* reduzido diante do orçamento de contexto do modelo. A Figura 1 apresenta o fluxo proposto: o comando em texto é submetido ao modelo, que pode produzir nenhuma, uma ou múltiplas chamadas estruturadas de ferramentas, conforme a solicitação e as operações disponíveis no *schema*.

As operações definidas representam funcionalidades compatíveis com sistemas de monitoramento apícola baseados em sensores de peso, temperatura e umidade, entre outras variáveis [Henry et al. 2019, Meikle and Holst 2015, Danieli et al. 2024, Cota et al. 2023]. A proposta não modifica a camada de sensoriamento, mas acrescenta uma camada de interação responsável por converter comandos em linguagem natural em chamadas estruturadas de ferramentas.

O protocolo experimental executa a inferência do modelo no host e no ESP32-S3 físico, mas não despacha as chamadas geradas para *handlers*. Portanto, não são realizadas consultas a sensores, operações sobre dados de colmeias ou ações em atuadores, tampouco execuções de ferramentas com dados simulados. A avaliação concentra-se na interpretação dos comandos e na correção das chamadas estruturadas produzidas pelo modelo.

2.2. Hardware e ambiente

O ambiente embarcado utilizado foi uma placa ESP32-S3-WROOM-1 N16R8, equipada com 16 MB de memória flash e 8 MB de PSRAM. O firmware experimental foi desenvolvido utilizando ESP-IDF v5.4.2 e executou localmente o modelo Needle 2, sem dependência de serviços externos durante a inferência.

A avaliação considerou dois ambientes de execução. O primeiro corresponde ao experimento histórico realizado em Linux, utilizando o motor de referência `nd_dump`.

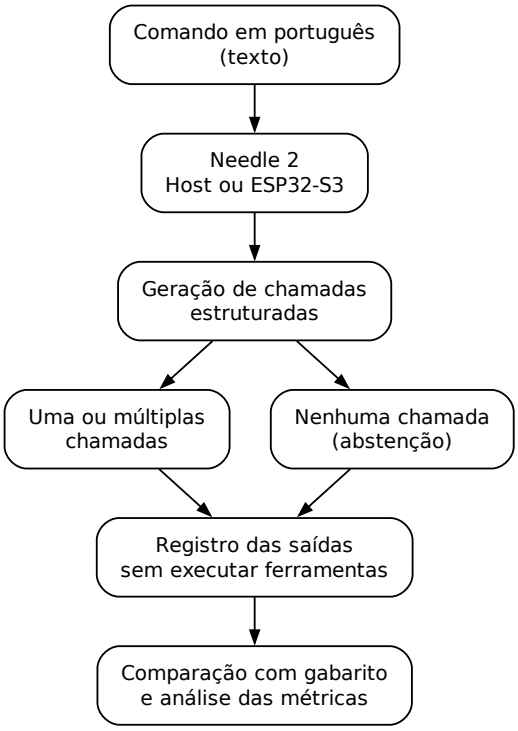


Figura 1. Fluxo experimental de geração e avaliação de chamadas estruturadas, sem execução de ferramentas.

Nesse ambiente, foram processadas 36 frases em português brasileiro, com uma execução por frase.

O segundo ambiente corresponde à execução sistemática no ESP32-S3 físico. Foram submetidas ao firmware as mesmas 36 frases utilizadas no experimento host. A coleta ocorreu em 25 de outubro de 2026, por meio da interface serial USB, identificada no ambiente experimental como `/dev/ttyACM0`.

O protocolo embarcado utilizou uma sessão persistente de inferência, com o modelo inicializado antes do processamento das solicitações. O raciocínio explícito foi desabilitado mediante o comando `!think 0`, cuja confirmação foi registrada pelo coletor. Foram configurados até 96 novos tokens por solicitação e timeout de 240 segundos por caso.

Os 36 casos foram concluídos, sem registros de casos incompletos. Os resultados foram obtidos por inferência real no ESP32-S3, não por simulação ou reprodução das respostas anteriormente geradas no host.

A avaliação concentrou-se na geração de chamadas estruturadas de ferramentas. Embora o modelo tenha produzido comandos associados a operações de monitoramento e inspeção de colmeias, nenhuma dessas chamadas foi executada fisicamente sobre sensores ou atuadores durante o experimento.

Os resultados dos ambientes host e ESP32-S3 foram registrados separadamente. Essa distinção permite comparar as chamadas geradas e analisar o desempenho temporal da execução embarcada, sem atribuir ao hardware medições realizadas exclusivamente no host.

2.3. Schema de ferramentas

O schema foi limitado a três ferramentas para reduzir a ocupação da janela de contexto documentada para o Needle 2, de 256 tokens [Cactus Compute 2026]: `consultar_status_colmeia(colmeia_id)`, `listar_colmeias_alerta()` e `ativar_modo_inspecao(colmeia_id, duracao_min)`. Os nomes dos parâmetros e suas descrições foram definidos com vocabulário relacionado ao domínio apícola, incluindo termos como peso, temperatura, alerta e inspeção. O *schema* foi fornecido ao motor em formato JSON compactado, sem espaços em branco, conforme recomendado pela documentação do projeto de referência, com o objetivo de reduzir o uso de tokens de formatação desnecessários.

2.4. Conjunto de teste

O conjunto de teste é composto por 36 frases em português brasileiro, construídas manualmente e associadas previamente às respostas esperadas. Os casos foram distribuídos em cinco categorias: comandos diretos (N=8); variações de fala coloquial e numerais por extenso (N=8); parâmetros ausentes ou vagos (N=6), destinados a verificar se o modelo evita preencher argumentos não fundamentados no comando; frases ambíguas (N=6), incluindo referências a múltiplas colmeias, referências espaciais sem identificador numérico e solicitações mais específicas do que as operações disponíveis; e frases fora de escopo (N=8), para as quais se espera uma chamada de ferramenta vazia.

As categorias foram definidas para representar diferentes níveis de complexidade de interpretação e incluir casos limite relevantes para a avaliação. Os casos com parâmetros ausentes, ambiguidades e entradas fora de escopo permitem avaliar, além da seleção da ferramenta, a capacidade do modelo de evitar argumentos não fundamentados e chamadas indevidas.

2.5. Protocolo experimental e métricas

Foram avaliadas as mesmas 36 frases em português brasileiro, uma vez por ambiente: Linux host, com `nd_dump`, e ESP32-S3 físico. O limite de geração foi de 96 novos tokens por solicitação, com raciocínio explícito desabilitado. Os tempos máximos foram de 300 s no protocolo histórico do host e 240 s no ESP32-S3. Temperatura, *top-k* e *top-p* não constam do manifesto histórico e não são presumidos. As saídas dos dois ambientes foram registradas separadamente.

A métrica principal de correção funcional foi a correspondência exata (*exact match*) entre a sequência de chamadas produzida pelo modelo e a sequência esperada no gabarito. A comparação considera os nomes das ferramentas, a quantidade de chamadas e os respectivos argumentos. Uma abstenção correta corresponde à ausência de chamadas quando nenhuma operação é suficientemente determinada ou suportada pelo contrato de ferramentas.

O gabarito histórico apresentou três casos sem representação avaliável da resposta esperada (casos 19, 23 e 25). Por esse motivo, a avaliação funcional original utiliza 33

casos avaliáveis, preservando os 36 registros de inferência. Os casos não avaliáveis não são automaticamente classificados como erros do modelo.

Uma auditoria posterior identificou inconsistências adicionais no gabarito histórico, incluindo casos em que a resposta esperada omitia argumentos obrigatórios do *schema*. Foi então elaborado um gabarito revisado, com 36 respostas esperadas estruturalmente compatíveis com o contrato das ferramentas. Os resultados obtidos com esse gabarito constituem uma reavaliação retrospectiva das saídas já coletadas, não um novo experimento nem uma substituição silenciosa do protocolo original.

Além da acurácia funcional, foram consideradas a concordância exata entre as chamadas geradas nos dois ambientes e a conformidade estrutural das chamadas com o *schema*. A conformidade estrutural verifica a presença de ferramentas reconhecidas e argumentos obrigatórios válidos, mas não implica correção semântica da resposta.

Para o ESP32-S3, foram analisados os tempos de processamento registrados durante a execução real, incluindo latência total por solicitação, tempo de *prefill*, tempo de geração e taxa de geração de tokens. Também foram examinados os registros de memória disponibilizados pelo firmware. Essas medições caracterizam exclusivamente o ambiente embarcado e não são inferidas a partir dos tempos observados no host.

Como cada frase foi executada apenas uma vez em cada ambiente, o estudo não permite estimar a variabilidade entre repetições. A comparação pareada dos acertos foi complementada pelo teste exato de McNemar, interpretado de forma exploratória, sem pressupor equivalência entre os ambientes na ausência de diferença estatisticamente significativa.

Nenhuma chamada produzida pelo modelo foi executada fisicamente sobre sensores ou atuadores. A avaliação concentrou-se na interpretação dos comandos e na geração das chamadas estruturadas correspondentes.

3. Resultados

3.1. Correção funcional e concordância entre ambientes

A avaliação compreendeu 36 solicitações em português brasileiro, executadas uma vez no host e uma vez no ESP32-S3. No gabarito histórico, três solicitações (casos 19, 23 e 25) não possuíam respostas esperadas avaliáveis. Consequentemente, a acurácia funcional histórica foi calculada sobre 33 casos.

O motor host apresentou 13 acertos em 33 casos avaliáveis (39,39%), enquanto a execução real no ESP32-S3 apresentou 14 acertos (42,42%). A Tabela 1 apresenta os resultados por categoria.

As sequências de chamadas produzidas nos dois ambientes foram idênticas em 34 das 36 solicitações (94,44%). As divergências ocorreram nos casos 6 e 34. No caso 6, o ESP32-S3 produziu uma chamada adicional de inspeção, além da chamada observada no host. No caso 34, referente a uma solicitação fora do escopo das ferramentas, o host gerou uma chamada indevida, enquanto o ESP32-S3 não produziu chamadas.

Entre os 33 casos avaliáveis pelo gabarito histórico, houve 13 acertos simultâneos, um acerto exclusivo do ESP32-S3 e nenhum acerto exclusivo do host. O teste exato de

Tabela 1. Correção funcional por categoria, segundo o gabarito histórico.

Categoria	Avaliáveis	Host	ESP32-S3
Diretos	8	6/8	6/8
Variações de fala	8	3/8	3/8
Parâmetro implícito	5	1/5	1/5
Ambíguos	4	1/4	1/4
Fora de escopo	8	2/8	3/8
Total	**33**	**13/33**	**14/33**

McNemar apresentou $p = 1{,}000$, sem evidência de diferença estatisticamente significativa na amostra observada. Esse resultado não estabelece equivalência entre os ambientes.

3.2. Desempenho da execução embarcada

A coleta real no ESP32-S3 concluiu as 36 solicitações previstas, sem casos incompletos. Todas as 36 saídas tiveram chamadas estruturadas extraídas em formato JSON válido. Isso não implica correção funcional das respostas.

A latência total média observada foi de 35,85 s, com desvio-padrão de 10,48 s e mediana de 34,04 s. Os tempos médios registrados para *prefill* e geração foram, respectivamente, 14,60 s e 18,15 s. A taxa média de geração foi de 1,378 token/s.

A Tabela 2 resume as principais medições.

Tabela 2. Desempenho observado no ESP32-S3 em 36 solicitações.

Métrica	Valor
Latência total média	35,85 s
Latência total mediana	34,04 s
Desvio-padrão da latência	10,48 s
Tempo médio de *prefill*	14,60 s
Tempo médio de geração	18,15 s
Taxa média de geração	1,378 token/s
Tokens gerados por solicitação (média)	25,06

Foram identificadas 35 chamadas de ferramentas nas 36 respostas embarcadas. Todas as 35 chamadas apresentaram conformidade estrutural com as ferramentas e os argumentos obrigatórios do contrato utilizado. Entretanto, a conformidade estrutural não implica que a ferramenta selecionada ou seus argumentos sejam semanticamente adequados à solicitação.

Os registros de memória livre antes e após cada solicitação não evidenciaram redução líquida nas medições correspondentes de PSRAM e memória interna. Essa observação não permite concluir ausência de fragmentação, vazamentos transitórios ou outros problemas de gerenciamento de memória.

3.3. Reavaliação retrospectiva do gabarito

Uma auditoria posterior ao experimento identificou inconsistências no gabarito histórico. Foram revisadas oito respostas esperadas, preservando integralmente as 36 frases originais e os registros de inferência dos dois ambientes.

O gabarito revisado contém 36 casos estruturalmente avaliáveis. Aplicado retrospectivamente às saídas já coletadas, resultou em 13 acertos no host (36,11%) e 14 no ESP32-S3 (38,89%).

Na versão revisada, 17 solicitações exigiam abstenção, isto é, ausência de chamadas de ferramentas. O host produziu chamadas indevidas em 15 desses casos, enquanto o ESP32-S3 apresentou esse comportamento em 14 casos. A elevada frequência de chamadas não solicitadas indica uma limitação relevante para interfaces que possam acionar dispositivos físicos.

O caso 23 ilustra a importância da auditoria do gabarito. A solicitação referente às colmeias 3 e 4 produziu duas chamadas de consulta compatíveis com a intenção expressa. O gabarito histórico não continha uma resposta avaliável para esse caso, enquanto o gabarito revisado passou a reconhecer as duas chamadas como resposta correta.

Os resultados retrospectivos são apresentados como análise complementar e não substituem a avaliação histórica.

4. Discussão

4.1. Interpretação da correção funcional

Os resultados evidenciam limitações do checkpoint avaliado na interpretação de comandos em português relacionados à IoT apícola. Segundo o gabarito histórico, os comandos diretos apresentaram seis acertos em oito solicitações (75,0%) nos dois ambientes. Nas categorias envolvendo parâmetros implícitos e ambiguidades, os resultados foram inferiores, com um acerto em cinco e um em quatro casos avaliáveis, respectivamente.

A reavaliação retrospectiva reforçou a importância de distinguir a geração de chamadas estruturalmente válidas da decisão de executar uma ferramenta. Embora todas as 35 chamadas produzidas no ESP32-S3 fossem compatíveis com a estrutura do contrato utilizado, apenas 14 das 36 respostas foram funcionalmente corretas segundo o gabarito revisado.

Entre as 17 solicitações que exigiam abstenção nesse gabarito, o modelo gerou chamadas indevidas em 15 casos no host e 14 no ESP32-S3. Esse comportamento é especialmente relevante em sistemas de IoT, nos quais uma interpretação inadequada pode resultar em ações não pretendidas caso a execução seja autorizada sem validações adicionais.

Os resultados são compatíveis com a hipótese de que a interpretação linguística e a transferência para um domínio específico representem desafios para o modelo. Entretanto, o desenho experimental não permite isolar efeitos do idioma, do domínio ou da capacidade do modelo. Comparações com conjuntos equivalentes em outros idiomas e avaliações com adaptação ao domínio seriam necessárias para investigar essas hipóteses.

4.2. Comparação entre host e ESP32-S3

A concordância exata de 34 das 36 sequências de chamadas (94,44%) indica que os dois ambientes produziram resultados predominantemente iguais para as solicitações avaliadas. As divergências observadas ocorreram nos casos 6 e 34.

A avaliação funcional histórica apresentou 13 acertos em 33 casos avaliáveis no host (39,39%) e 14 no ESP32-S3 (42,42%). O teste exato de McNemar não identificou diferença estatisticamente significativa ($p = 1{,}000$). Considerando o pequeno conjunto de teste e a ausência de repetições, não é possível concluir superioridade ou equivalência entre os ambientes.

A execução local das 36 solicitações no ESP32-S3 confirmou a viabilidade técnica da inferência embarcada nessa configuração. Entretanto, a latência média de 35,85 s e a taxa de geração de 1,378 token/s indicam restrições para interfaces que exijam respostas rápidas. A adequação temporal não foi avaliada com usuários finais.

4.3. Implicações para IoT apícola

Os resultados sugerem que a integração de modelos compactos de *tool-calling* a sistemas embarcados deve considerar mecanismos adicionais de segurança.

A validação estrutural de nomes de ferramentas e argumentos é necessária, mas insuficiente para garantir a adequação da operação solicitada. Em particular, comandos ambíguos, parâmetros obrigatórios ausentes e solicitações fora do escopo exigem políticas explícitas de abstenção ou confirmação antes de qualquer acionamento físico.

No experimento realizado, nenhuma chamada foi executada sobre sensores ou atuadores. Assim, os resultados demonstram a geração local de comandos estruturados, mas não validam o funcionamento de uma cadeia completa de controle físico de colmeias.

4.4. Limitações

O estudo possui limitações relevantes. Primeiro, o conjunto contém apenas 36 frases construídas manualmente, sem validação com apicultores ou revisão independente por múltiplos anotadores.

Segundo, cada frase foi executada uma única vez em cada ambiente, impedindo a estimativa da variabilidade entre execuções e restringindo a interpretação da comparação estatística.

Terceiro, o gabarito histórico apresentou três casos não avaliáveis e outras inconsistências de especificação. A revisão posterior foi documentada e analisada separadamente, mas não equivale a uma avaliação prospectiva independente.

Quarto, a execução embarcada foi realizada em uma configuração específica de ESP32-S3, sem comparação com outros microcontroladores, configurações de memória ou estratégias de otimização.

Quinto, não houve integração com sensores ou atuadores reais, tampouco avaliação de usabilidade com operadores do domínio apícola.

Por fim, foi utilizado o checkpoint público do modelo, sem adaptação específica ao português ou ao vocabulário do domínio. Essas restrições caracterizam os resultados como exploratórios e limitam sua generalização para aplicações reais.

5. Conclusão

Este trabalho apresentou uma avaliação exploratória do modelo compacto Needle 2 como mecanismo de interpretação de comandos em português para IoT apícola, comparando sua execução em Linux host e em um ESP32-S3 físico.

Foram processadas 36 solicitações em cada ambiente. Segundo o gabarito histórico, que continha 33 casos avaliáveis, a acurácia funcional foi de 39,39% no host e 42,42% no ESP32-S3. As chamadas estruturadas foram idênticas em 34 das 36 solicitações, sem evidência de diferença estatisticamente significativa entre os acertos pareados.

A execução embarcada concluiu todos os casos previstos, apresentando latência total média de 35,85 s e taxa média de geração de 1,378 token/s. Apesar da conformidade estrutural das chamadas produzidas, a correção funcional permaneceu limitada, especialmente em solicitações que exigiam abstenção.

Os resultados demonstram a possibilidade de executar localmente o modelo e gerar comandos estruturados em um microcontrolador, mas não sustentam seu emprego autônomo para acionamento físico de dispositivos no cenário avaliado.

Como trabalhos futuros, pretende-se ampliar o conjunto de comandos, realizar execuções repetidas, obter avaliação de especialistas do domínio, investigar estratégias de adaptação ao português e otimizar o desempenho embarcado. A integração controlada com sensores e atuadores deverá ser acompanhada de mecanismos de validação semântica, abstenção e confirmação das operações propostas.

Referências

Cactus Compute (2026). Needle 2: tiny function-calling ai for edge devices. `https://github.com/cactus-compute/needle`. Acessado em setembro de 2026.

Cota, D., Martins, J., Mamede, H., and Branco, F. (2023). Bhivesense: An integrated information system architecture for sustainable remote monitoring and management of apiaries based on iot and microservices. *Journal of Open Innovation: Technology, Market, and Complexity*, 9(3):100110.

Danieli, P. P., Addeo, N. F., Lazzari, F., Manganello, F., and Bovera, F. (2024). Precision beekeeping systems: State of the art, pros and cons, and their application as tools for advancing the beekeeping sector. *Animals*, 14(1):70.

Erdogan, L. E., Lee, N., Jha, S., Kim, S., Tabrizi, R., Moon, S., Hooper, C. R. C., Anumanchipalli, G., Keutzer, K., and Gholami, A. (2024). Tinyagent: Function calling at the edge. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 80–88.

Espressif Systems (2026). Esp-sr: Speech recognition framework. `https://github.com/espressif/esp-sr`. Acessado em setembro de 2026.

Henry, E., Adamchuk, V., Stanhope, T., Buddle, C., and Rindlaub, N. (2019). Precision apiculture: Development of a wireless sensor network for honeybee hives. *Computers and Electronics in Agriculture*, 156:138–144.

Meikle, W. G. and Holst, N. (2015). Application of continuous monitoring of honeybee colonies. *Apidologie*, 46(1):10–22.

Ndubuaku, H., Mosoyan, K., Mroz, J., Cylich, N., Kumar, S., Sandhu, P., Shemet, R., and Lee, J. H. (2026). A controlled study of attention-only transformers. Cactus Compute, Inc.